



Applying Federated Learning for the Diagnosis of Lung Diseases in Remote Regions

01

INDÍCE

- INTRODUÇÃO;
- IOT E NECESSIDADES COMPUTACIONAIS;
- TRBALHOS RELACIONADOS
- MATERIAIS E MÉTODOS;
- RESULTADOS;
- CONCLUSÃO.

INTRODUÇÃO À IA NA SAÚDE



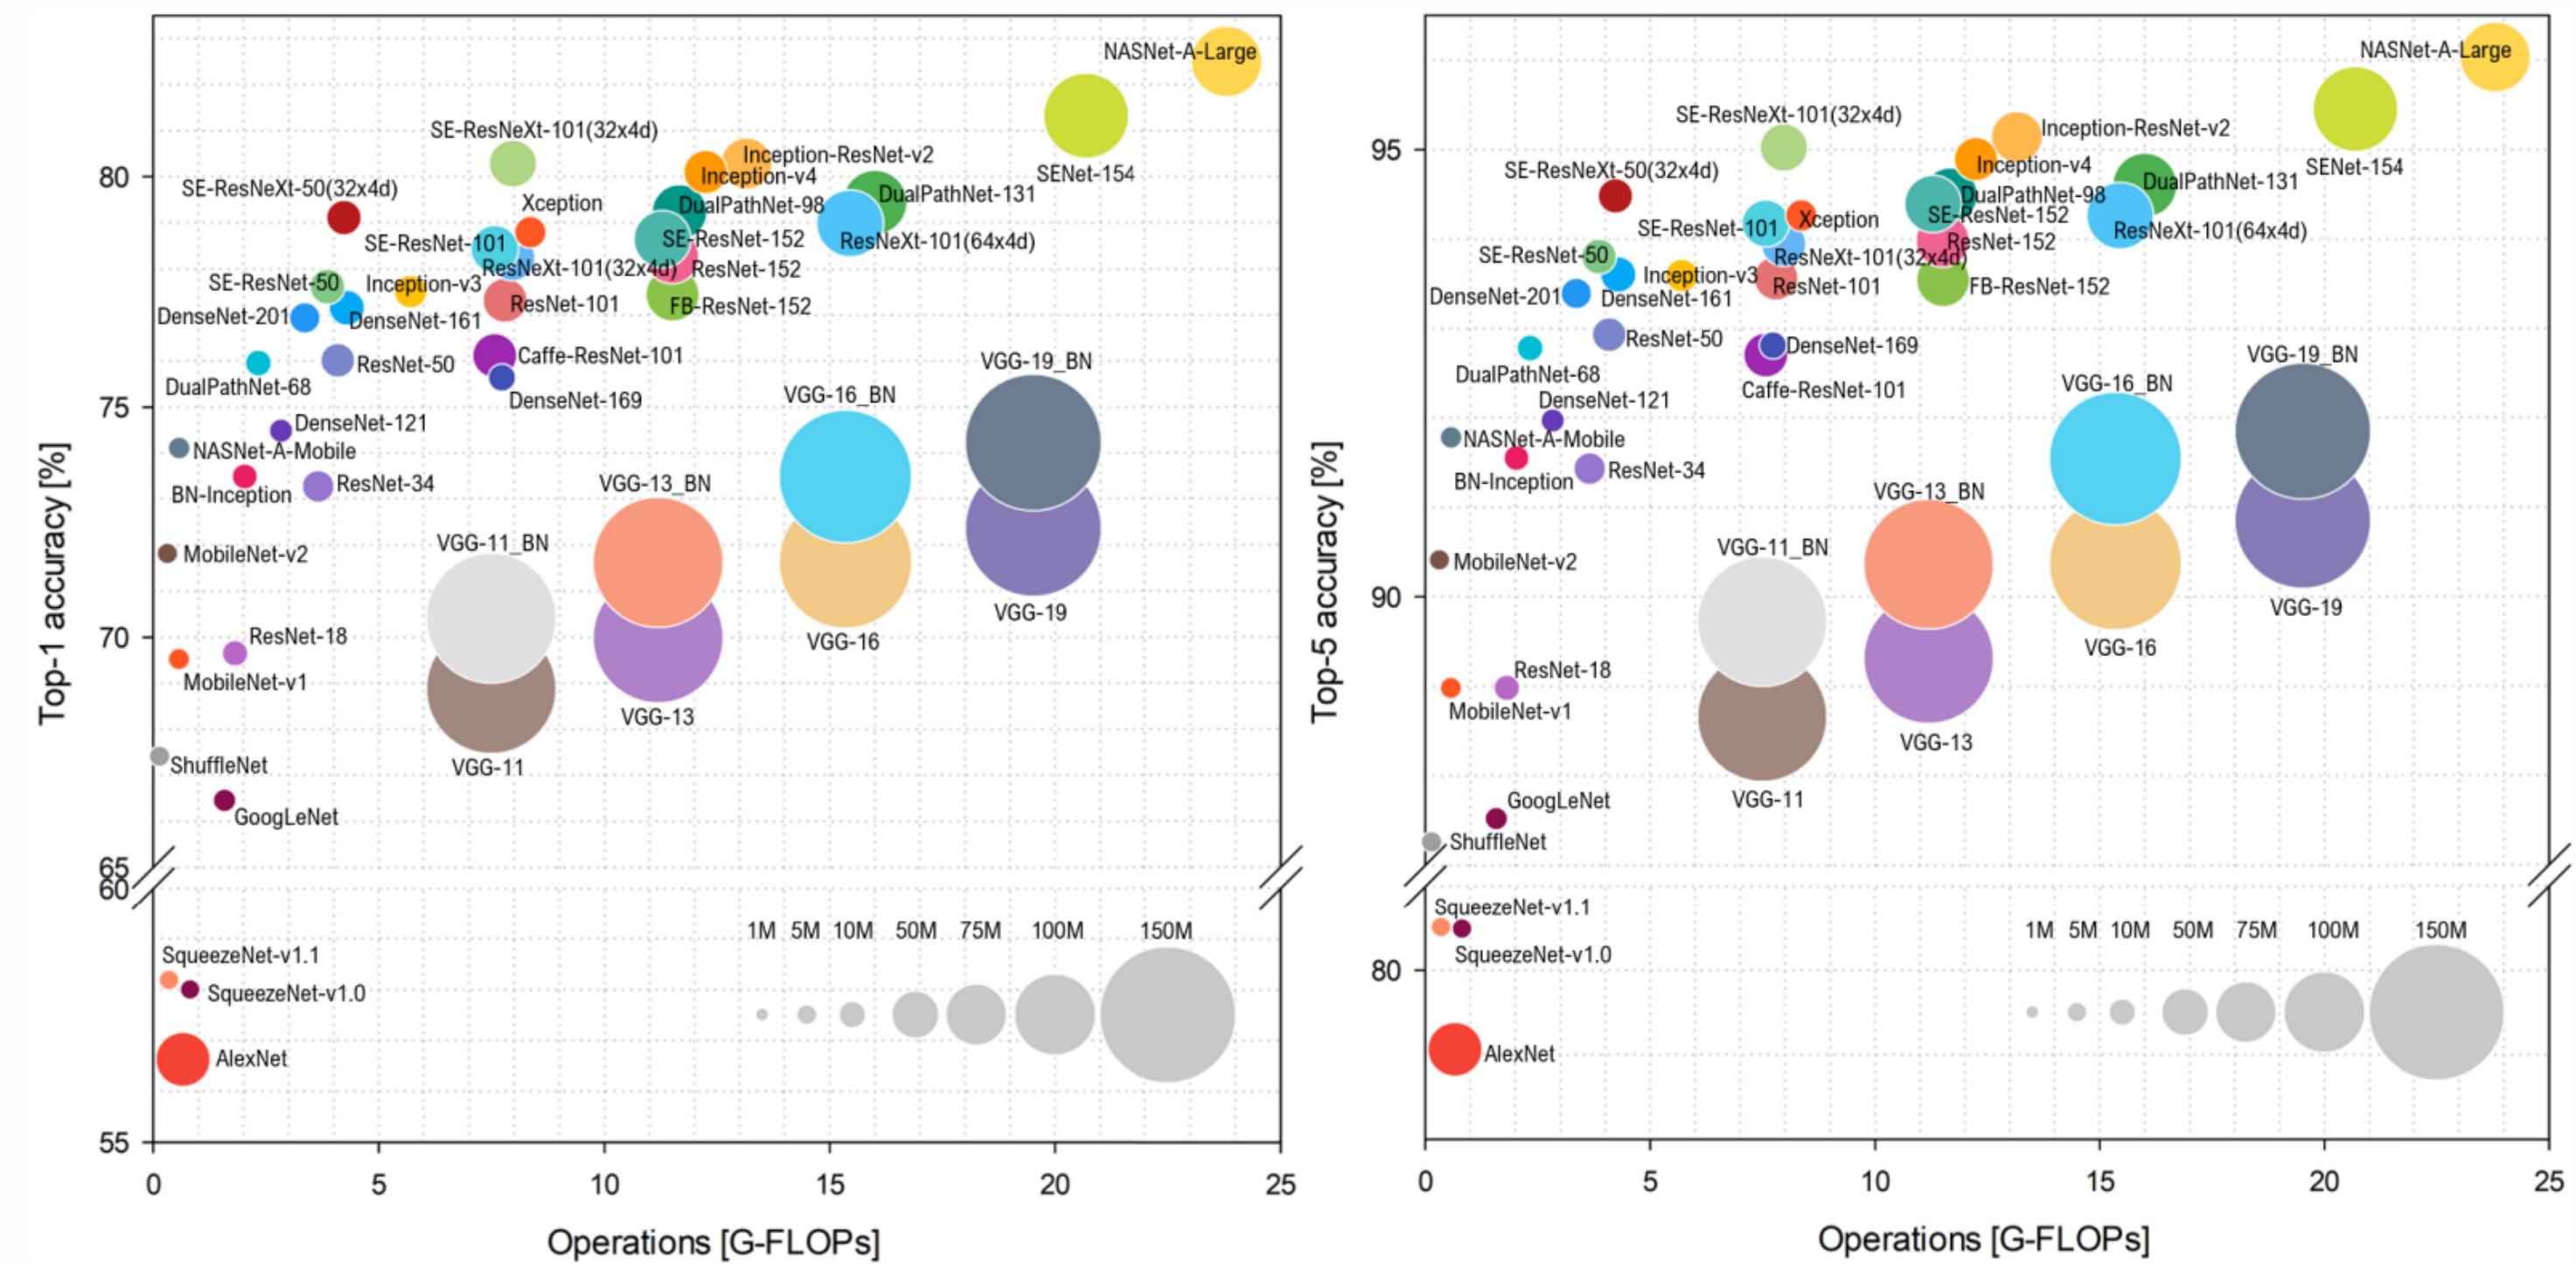
INTRODUÇÃO

Para enfrentar os desafios globais e brasileiros na de saúde, especialmente em áreas remotas com acesso limitado a recursos médicos, um protótipo baseado em tecnologias de Aprendizagem Federada e tecnologias de Internet das Coisas foi desenvolvido.

Este sistema é projetado para diagnosticar pneumonia por meio de raios-x, usando arquivos de imagens para fornecer diagnósticos rápidos e precisos. O seu objetivo é Destina-se a zonas remotas, pequenas cidades e regiões ribeirinhas onde o acesso a médicos e serviços de saúde é limitado ou escasso.

O sistema é particularmente útil em locais onde o equipamento disponível não têm capacidade de processamento suficiente para efetuar diagnósticos. Ao fornecer diagnósticos preliminares rápidos, este sistema pode ajudar as limitações de tempo dos médicos, a localização remota dos pacientes e outros obstáculos à prestação de cuidados de saúde eficazes.

INTERNET DAS COISAS (IOT) E NECESSIDADES COMPUTACIONAIS





SAÚDE TRABALHOS RELACIONADOS

Inatel

TRABALHOS RELACIONADOS

- O ARTIGO CLASSIFICATION OF PNEUMONIA ON CHEST X-RAY IMAGE USING TRANSFER LEARNING UTILIZOU-SE DA MESMA BASE DE DADOS QUE FOI USADA NESTE PROTÓTIPO.
- UTILIZOU TRANSFER LEARNING COM RESNET-50 E OBTEVE 92% DE ACURÁCIA.
- ESTE TRABALHO PROPOSTO OBTEVE APROXIMADAMENTE 95.5% DE ACURÁCIA COM SQUEEZENET UTILIZANDO FEDERATED LEARNING.



EasyChair Preprint

Nº 10369

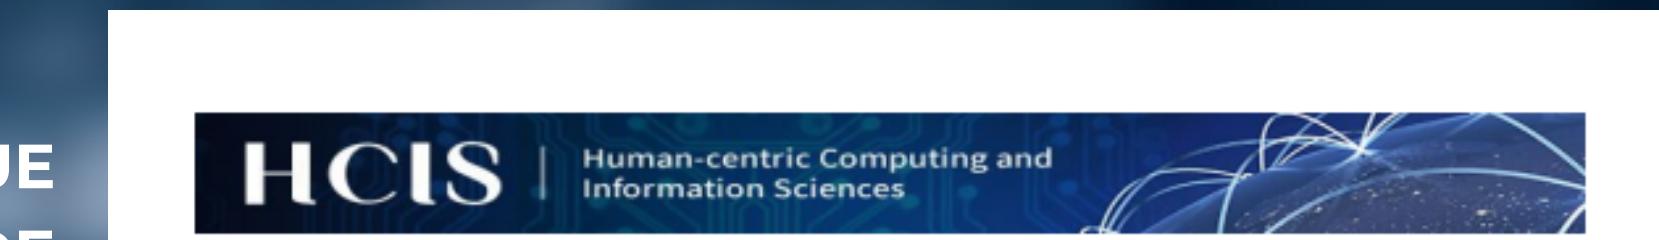
Classification of Pneumonia on Chest X-Ray Image Using Transfer Learning

Thi Bich Nhu Pham and Minh Hong Nguyen

Model	Train Acc (%)	Train Error rate (%)	Val Acc (%)	Val Error rate(%)
Model ResNet-50	92.0	8.9	91.8	8.2
Model Squeeze-Net (proposed)	95.5	5.0	95.4884	4.5116

TRABALHOS RELACIONADOS

- OUTRO TRABALHO FOI UM JOURNAL QUE UTILIZOU VÁRIAS TÉCNICAS EM UMA BASE DE DADOS SIMILAR.
- VÁRIOS MODELOS NO ESTADO DA ARTE FORAM COMPARADOS, SENDO QUE O MELHOR VALOR DE ACURÁCIA FOI DE 94.90%.
- NOSSO PROTÓTIPO ATINGIU 95.5% DE ACURÁCIA.
- AS ARQUITETURAS COMPARADAS FORAM VGG-16, MOBILENET V2, RESNET50, DENSENET, INCEPTION V3, COM A INCEPTION SENDO A MELHOR, TODAS UTILIZANDO TRANSFERLEARNING.
- O MODELO COM MELHOR RESULTADO FOI O VGG-19, NESTE JORNAL OBTEVE RESULTADO MUITO BOM MAS É UM MODELO GRANDE PARA IOT.



HCIS | Human-centric Computing and Information Sciences

RESEARCH (Research Manuscript) | Open Access

Human-centric Computing and Information Sciences (2022) 12:24
DOI: <https://doi.org/10.22967/HCIS.2022.12.024>
Received: November 26, 2021; Accepted: January 21, 2022; Published: May 30, 2022

An IoMT-Based Federated and Deep Transfer Learning Approach to the Detection of Diverse Chest Diseases Using Chest X-Rays

Barkha Kakkar¹, Prashant Johri¹, Yogesh Kumar², Hyunwoo Park³, Youngdoo Son³, and Jana Shafii^{4,*}

Model	Training		Validation	
	Acc (%)	Loss	Acc (%)	Loss
VGG-16	78.65	0.127	76.71	0.213
MobileNet V2	79.23	0.126	79.00	0.194
ResNet-50	79.29	0.186	79.07	0.194
DenseNet-161	80.02	0.186	82.71	0.193
Inception V3	94.56	0.187	94.90	0.185
Proposed model (SqueezeNet)	95.5	0.159827	95.4884	0.057891



A NA SÁUD MATERIAIS E MÉTODOS NA SÁUD

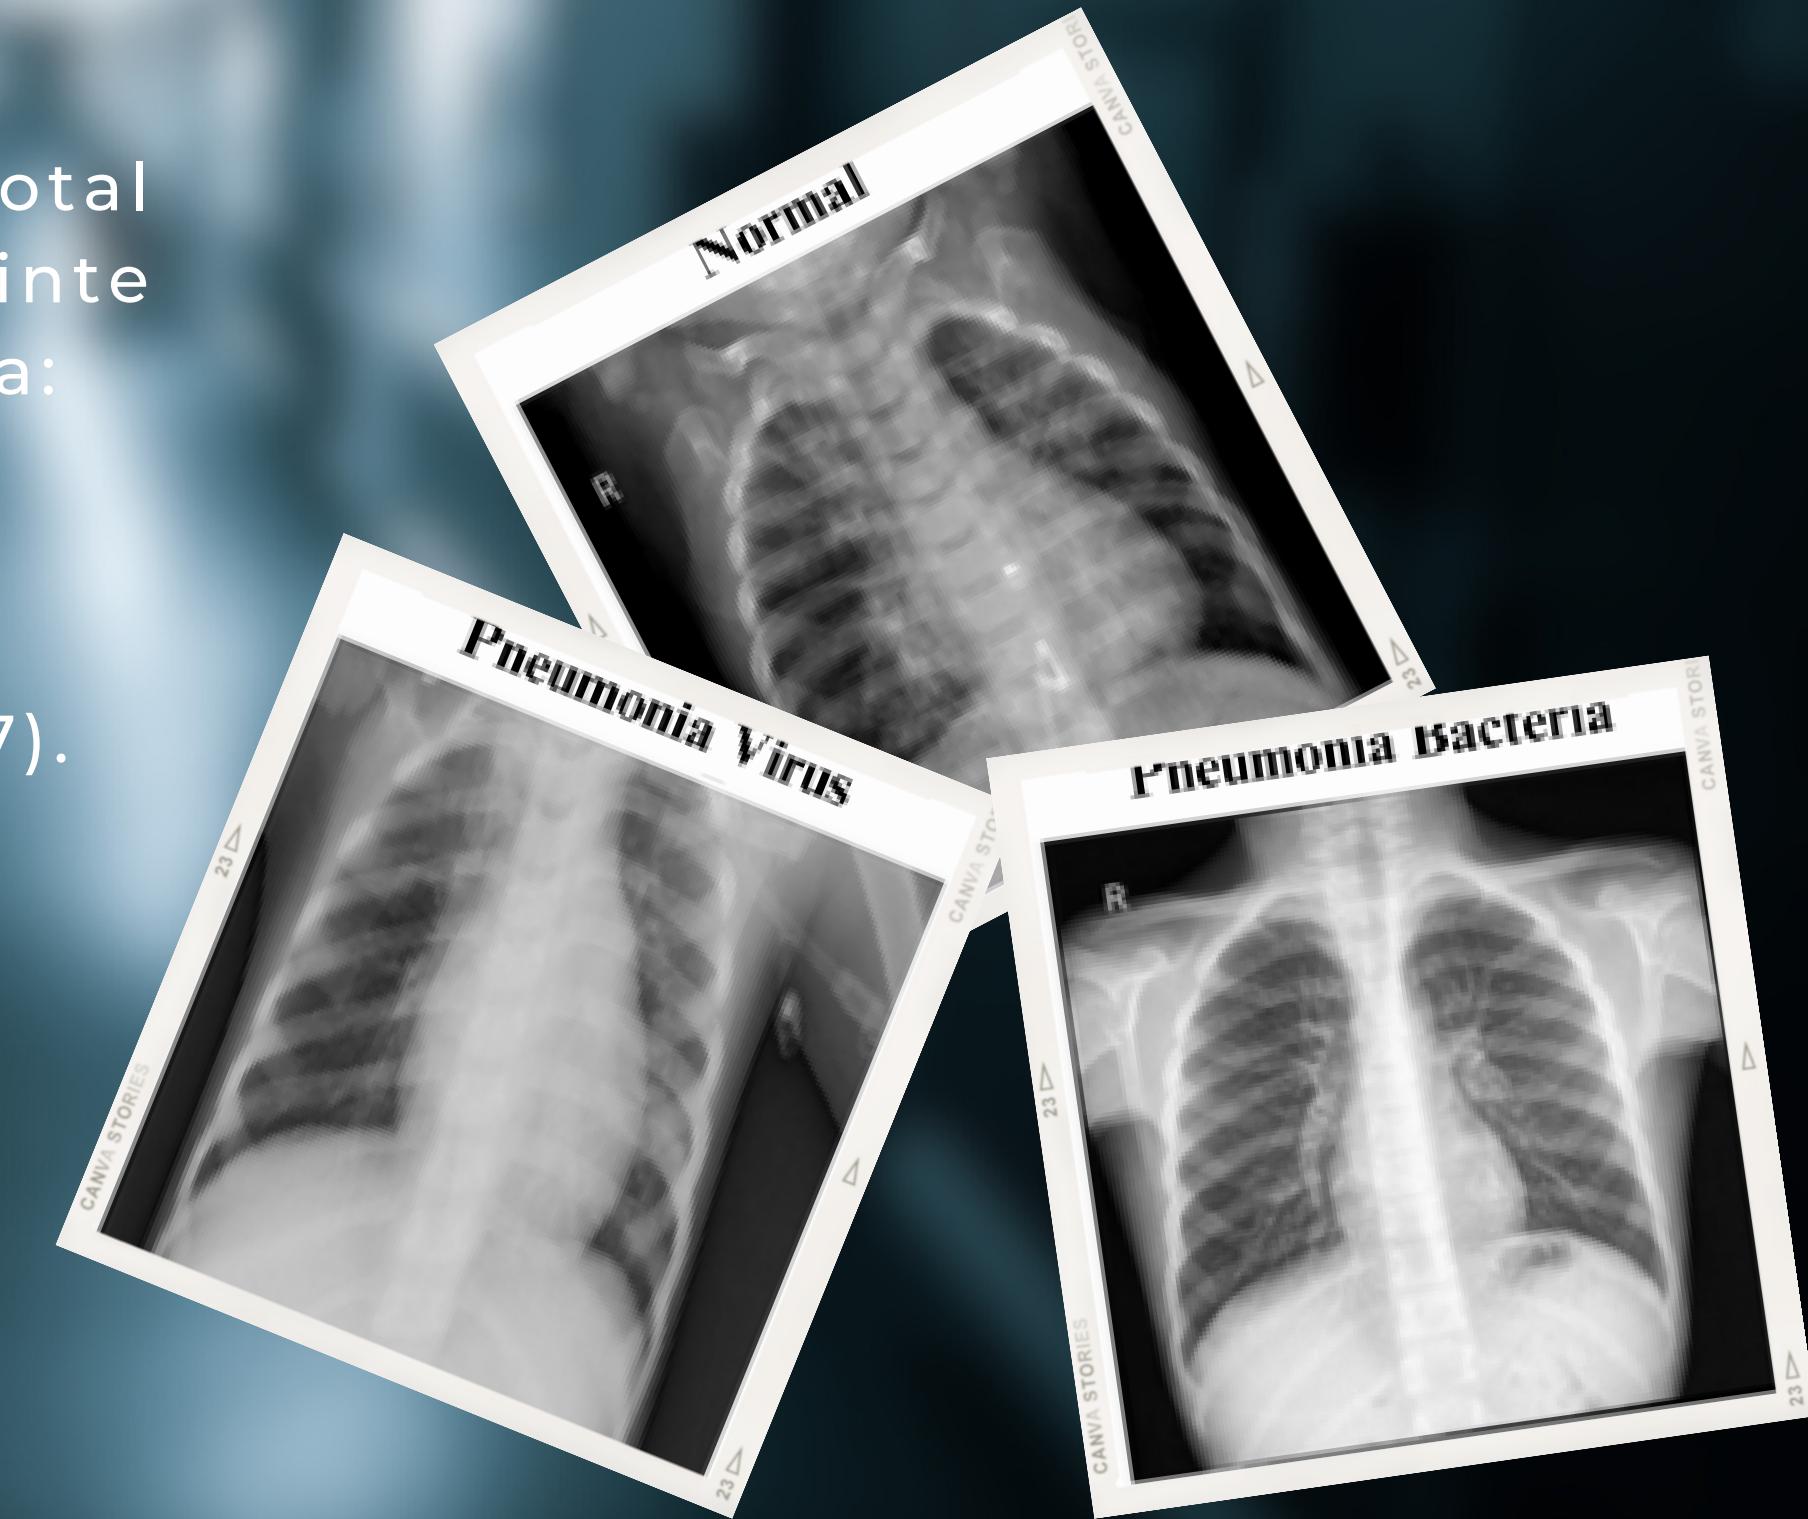
Inatel

DATASET

Trata-se de um conjunto de dados para a classificação da pneumonia com um total de 5.840 imagens, divididas em 4.672 para treino e 1.168 para testar o modelo.

O conjunto de dados fornece um total de três classes organizadas da seguinte forma organizadas da seguinte forma:

- I. Sem doença (1227);
- II. Pneumonia bacteriana (2238);
- III. Pneumonia pneumonia viral (1207).

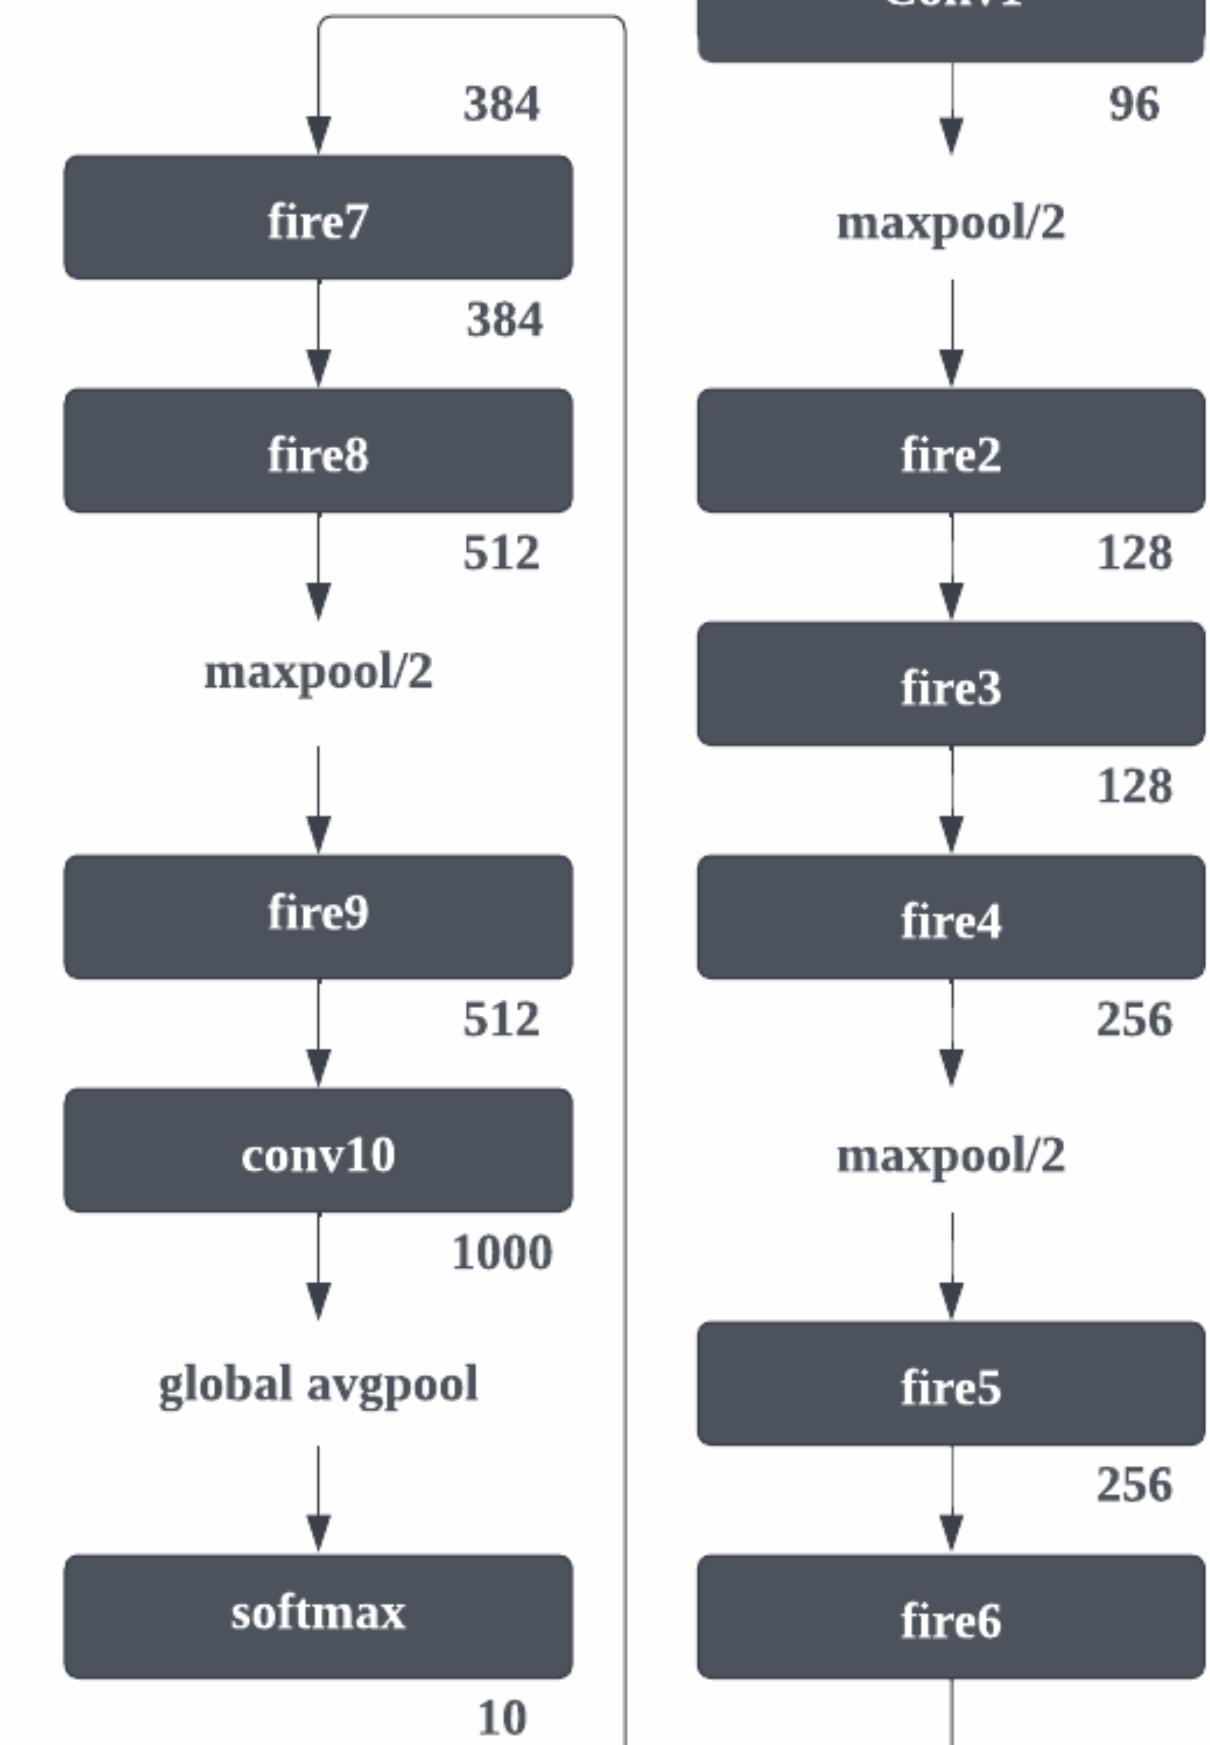


ARQUITETURA SQUEEZENET 1.1

O SqueezeNet 1.1 é uma rede neural convolucional que emprega estratégias de design para reduzir o número de parâmetros, com o uso de módulos de fire que comprimem parâmetros usando convoluções 1x11.

O SqueezeNet 1.1 tem 2,4 vezes menos computação e ligeiramente menos parâmetros do que o SqueezeNet 1.0, sem sacrificar a precisão.

Inatel



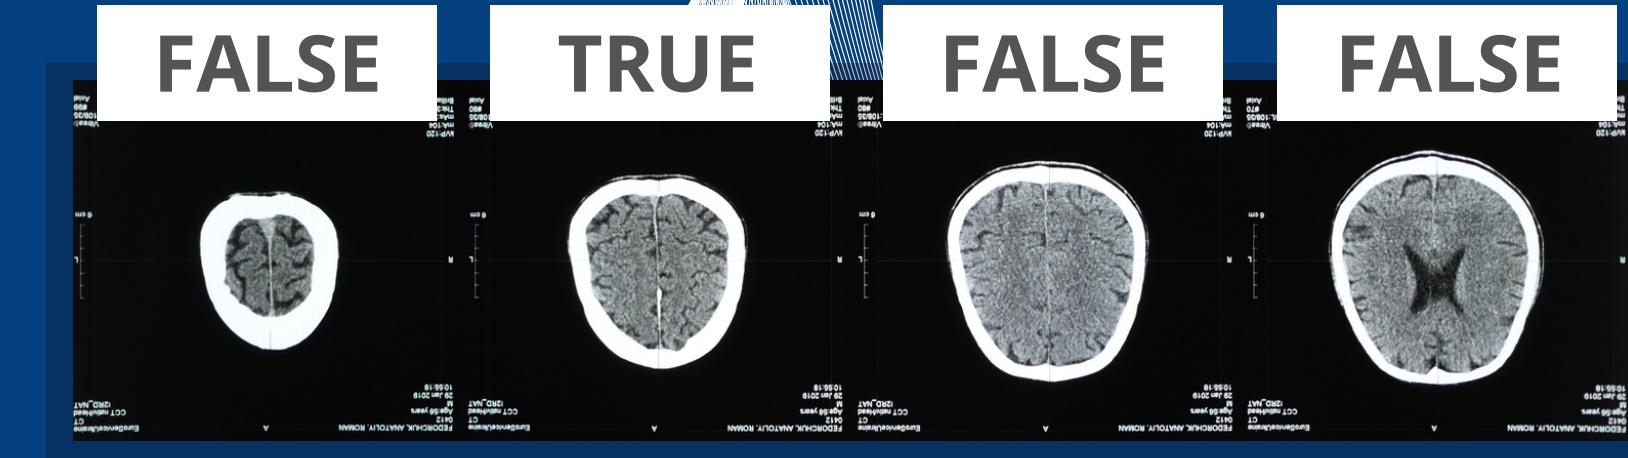
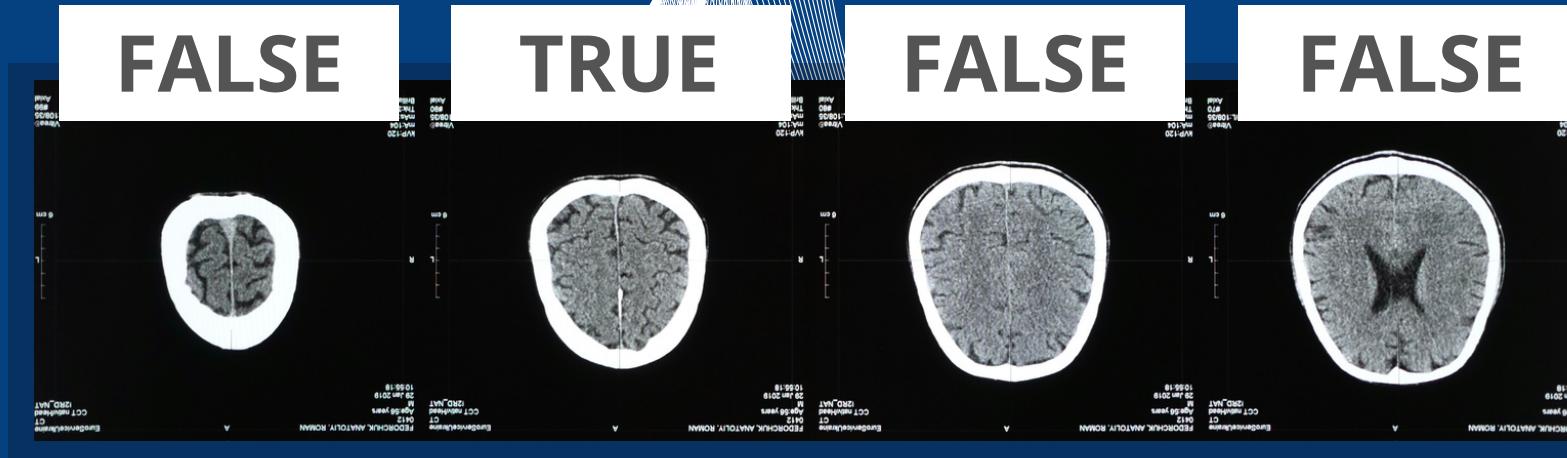
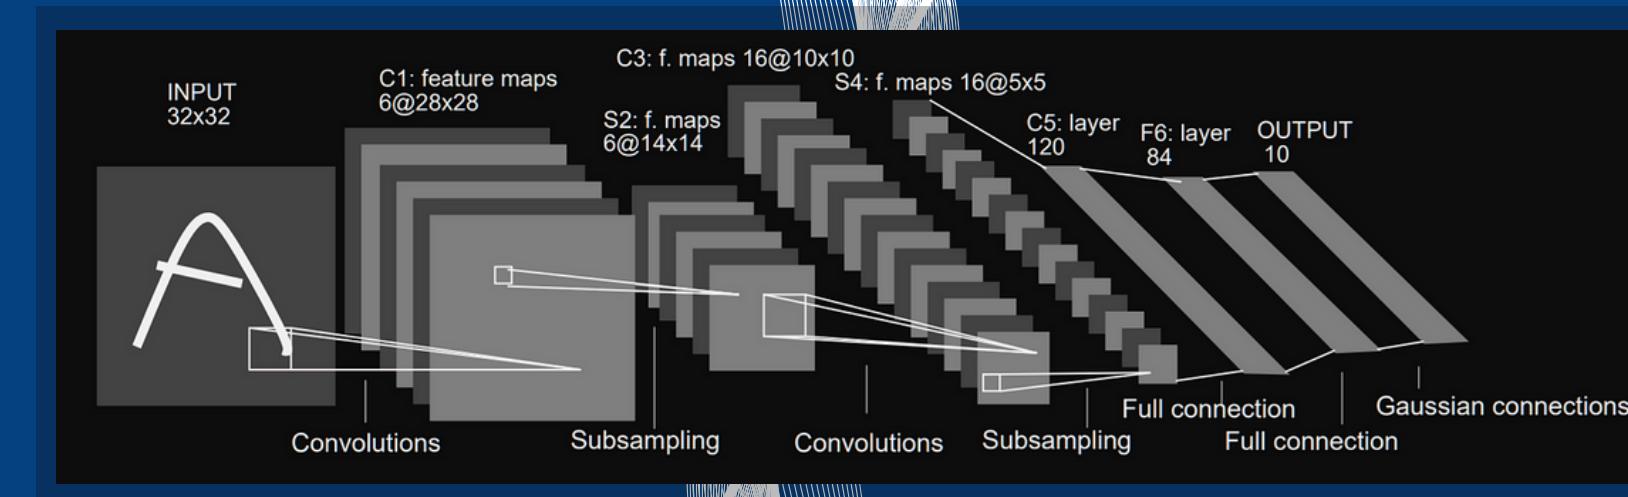
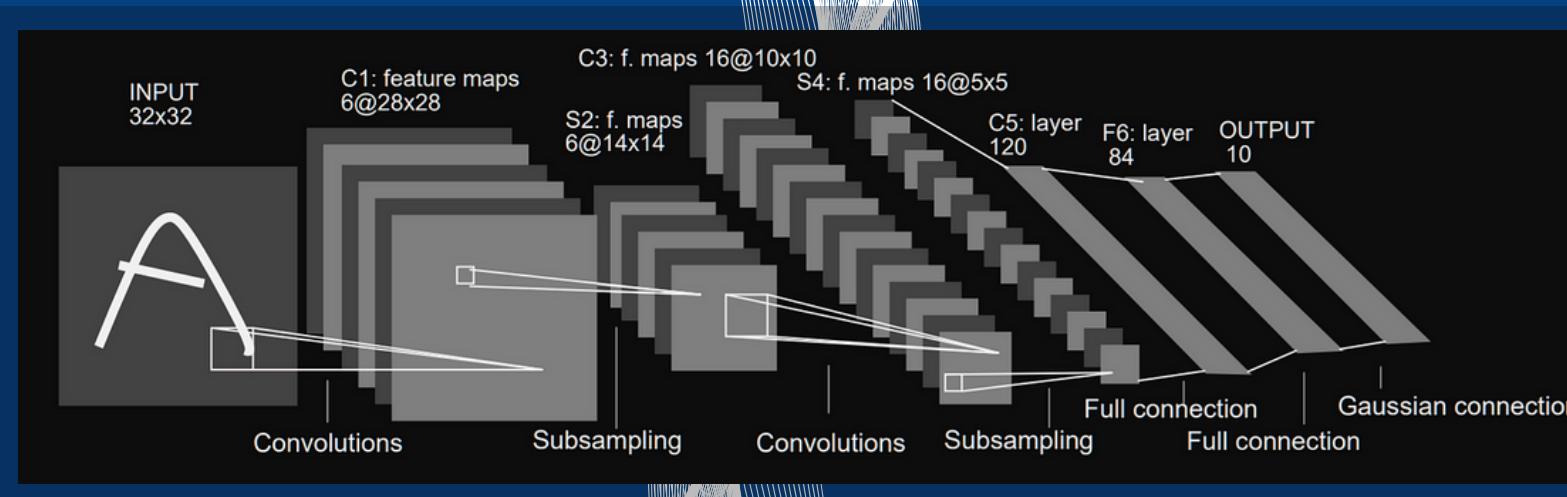
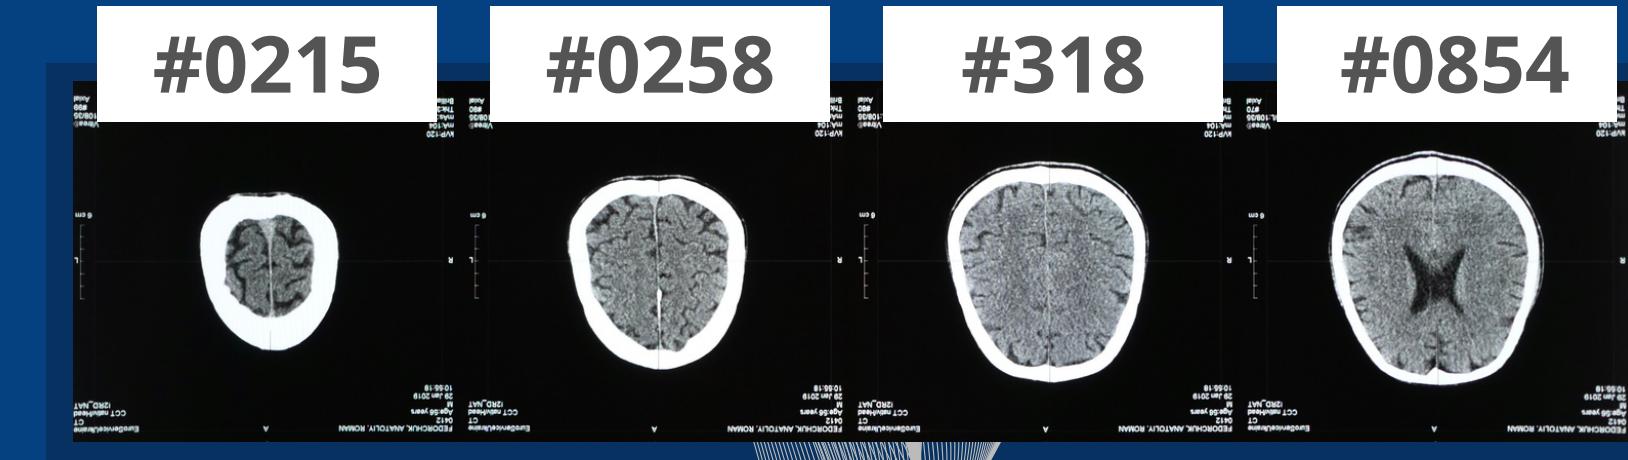
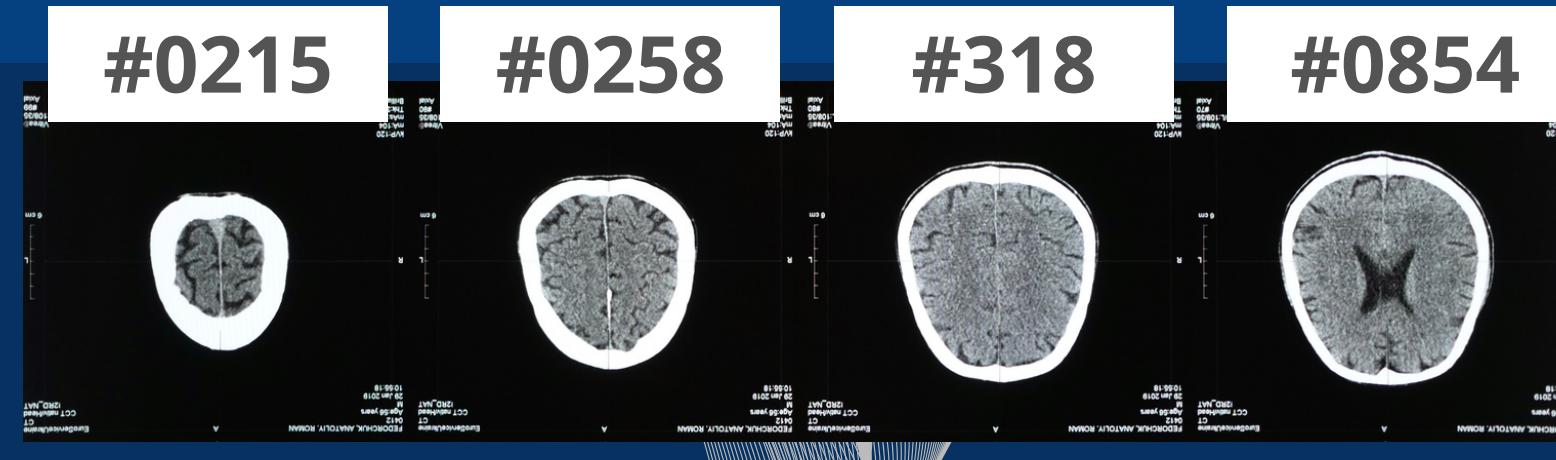
FL IN EMBEDDED DEVICES

O modelo final pode ser implementado em diferentes dispositivos embarcados como Raspberry Pi, Jeston Nano, Jetson AGX Xavier, dentre outros. Porém os requisitos computacionais impedem que ela seja implementada em microcontroladores como Arduino BLE de forma local.

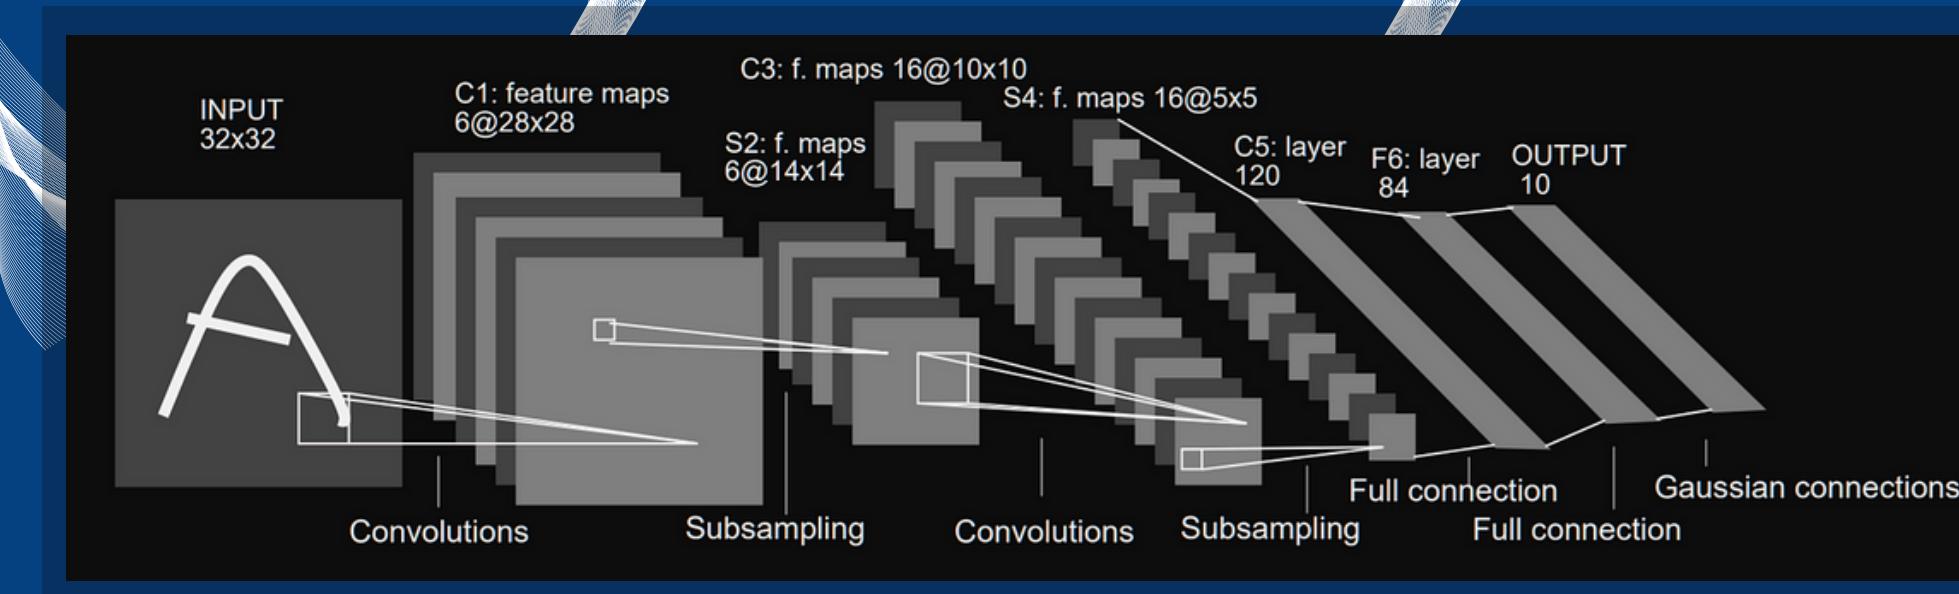
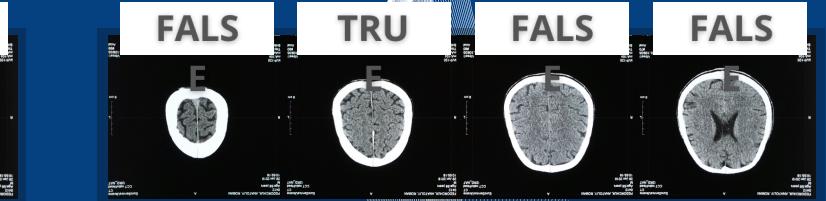
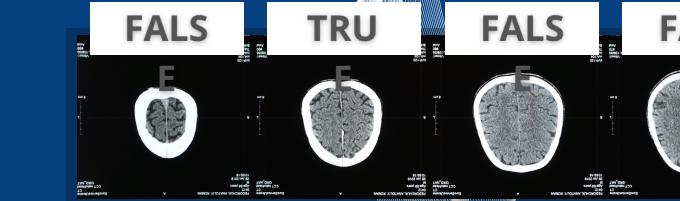
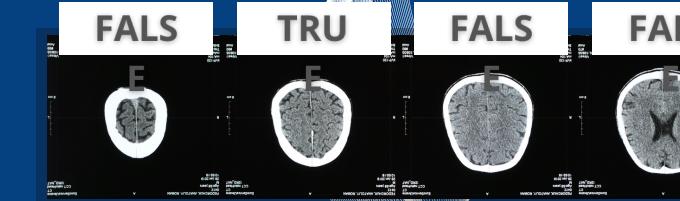
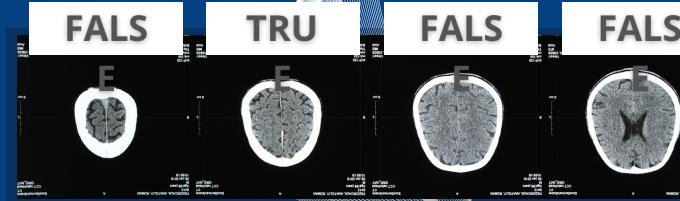
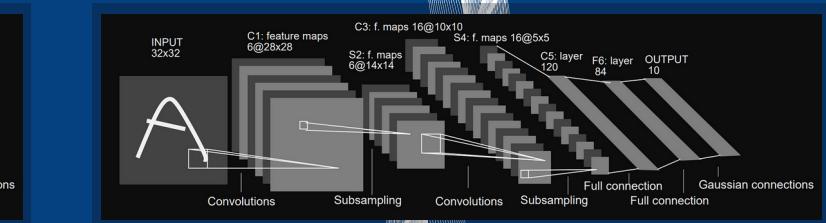
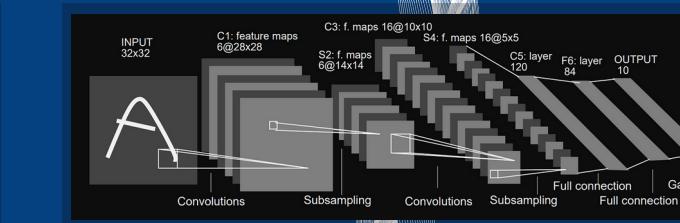
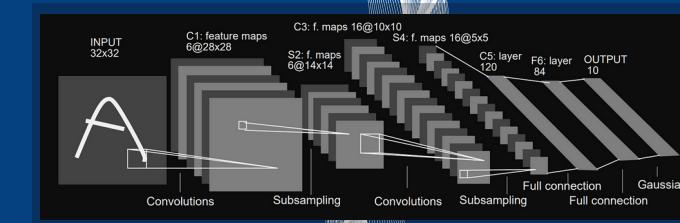
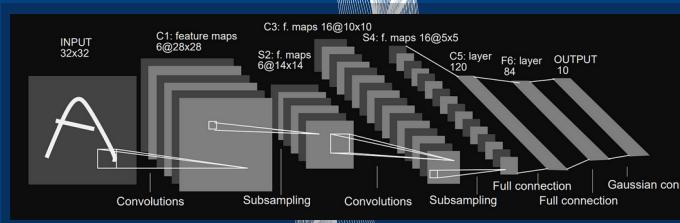
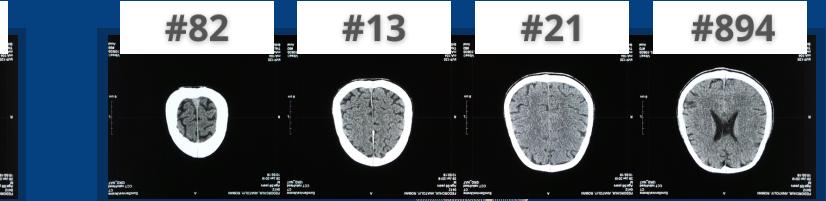
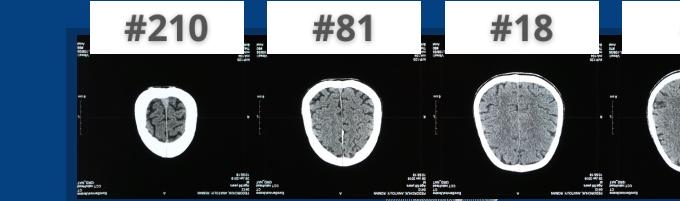
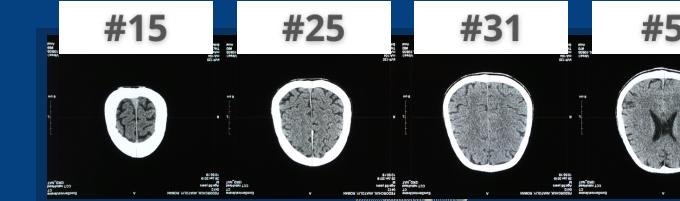
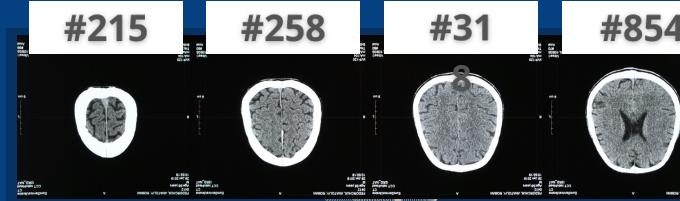
Uma alternativa seria o uso de recursos na nuvem de modo a executar todo processamento por meio de requisições a servidores com configurações suficientes para este tipo de tarefa.



02 TRADITIONAL APPROACH



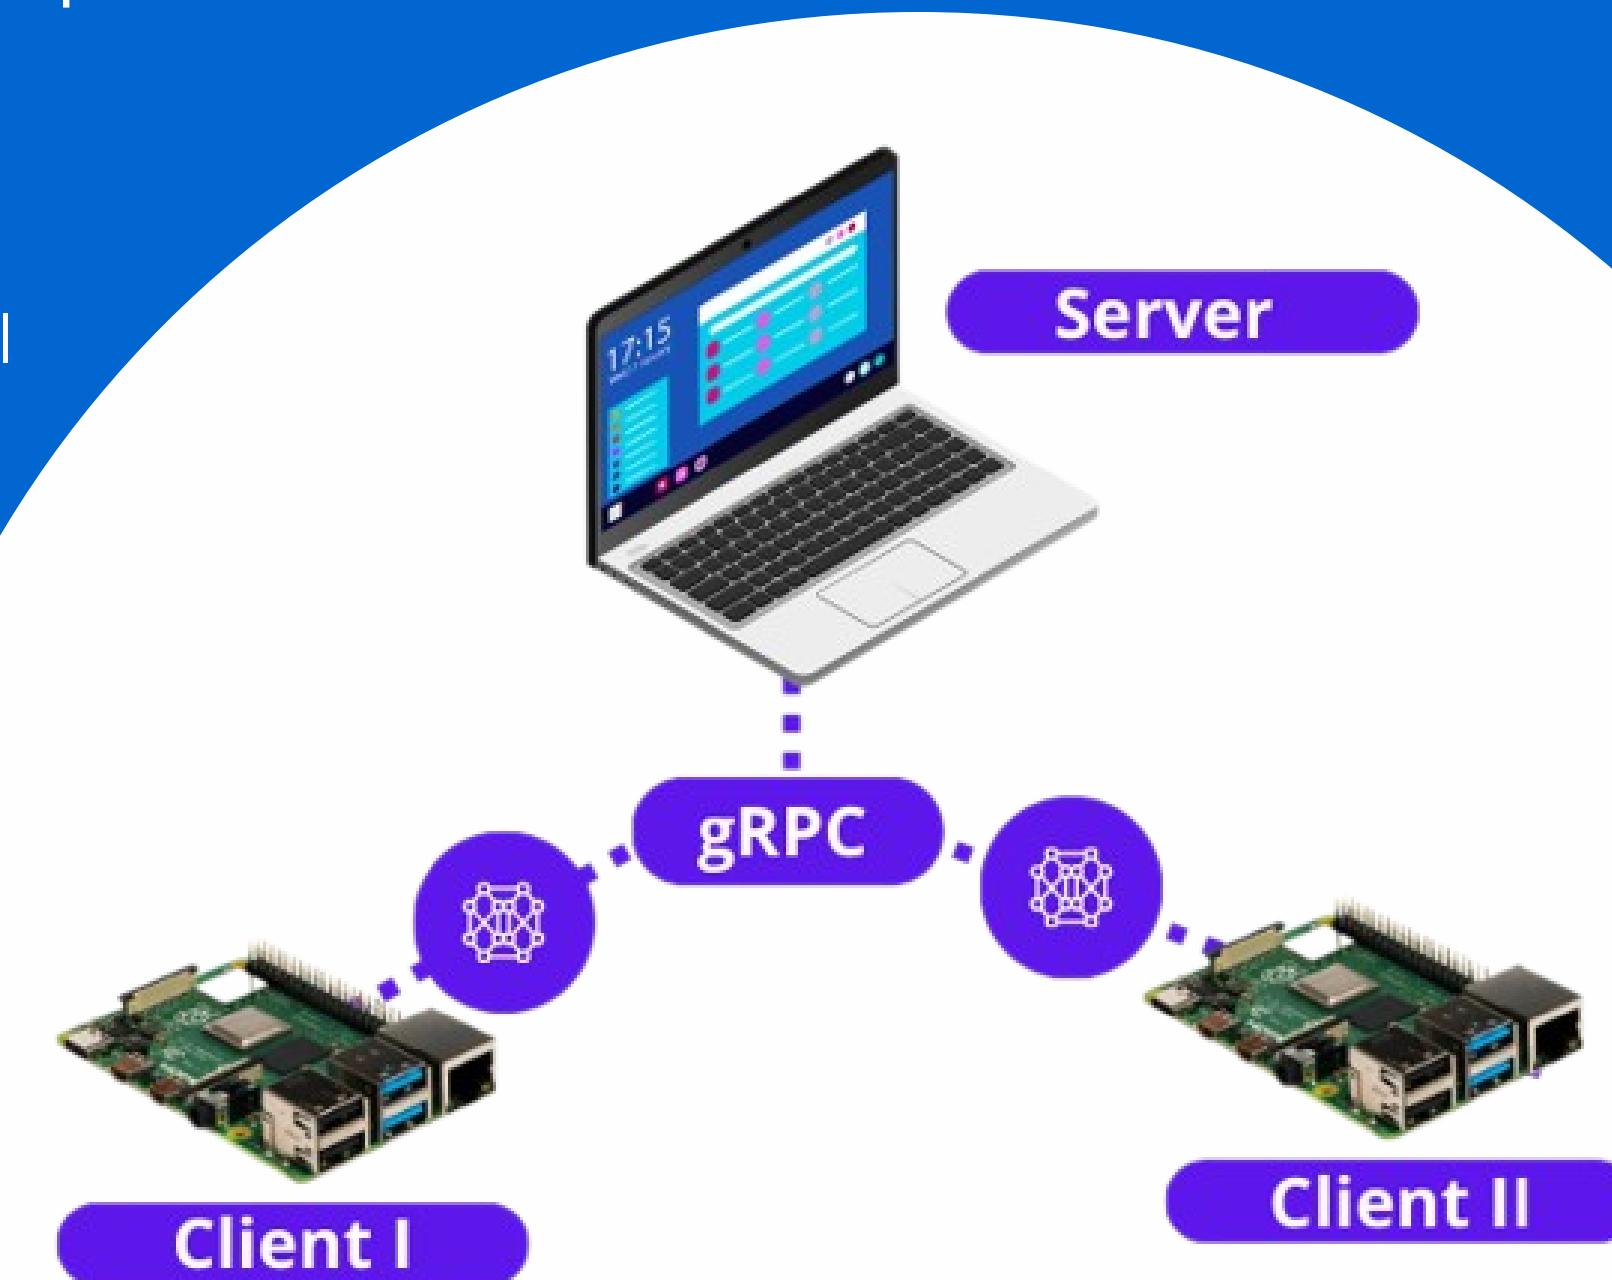
02 FL APPROACH



ARQUITETURA

O funcionamento do RPC está ligado a um modelo de client-server. Sendo assim, o solicitante é um client, enquanto que o fornecedor da informação é um serviço Server Side. A comunicação é feita de forma síncrona, exigindo que o cliente seja suspenso até que o server seja retornando.

O Servidor nesta arquitetura é responsável por agregar os pesos dos clientes e posteriormente compartilhar o novo modelo (global). Garantindo assim que todos os clientes tenham o melhor modelo disponível.



A NA SAÚDE

R E S U L T A D O S

A NA SAÚDE

Inatel

RESULTADOS

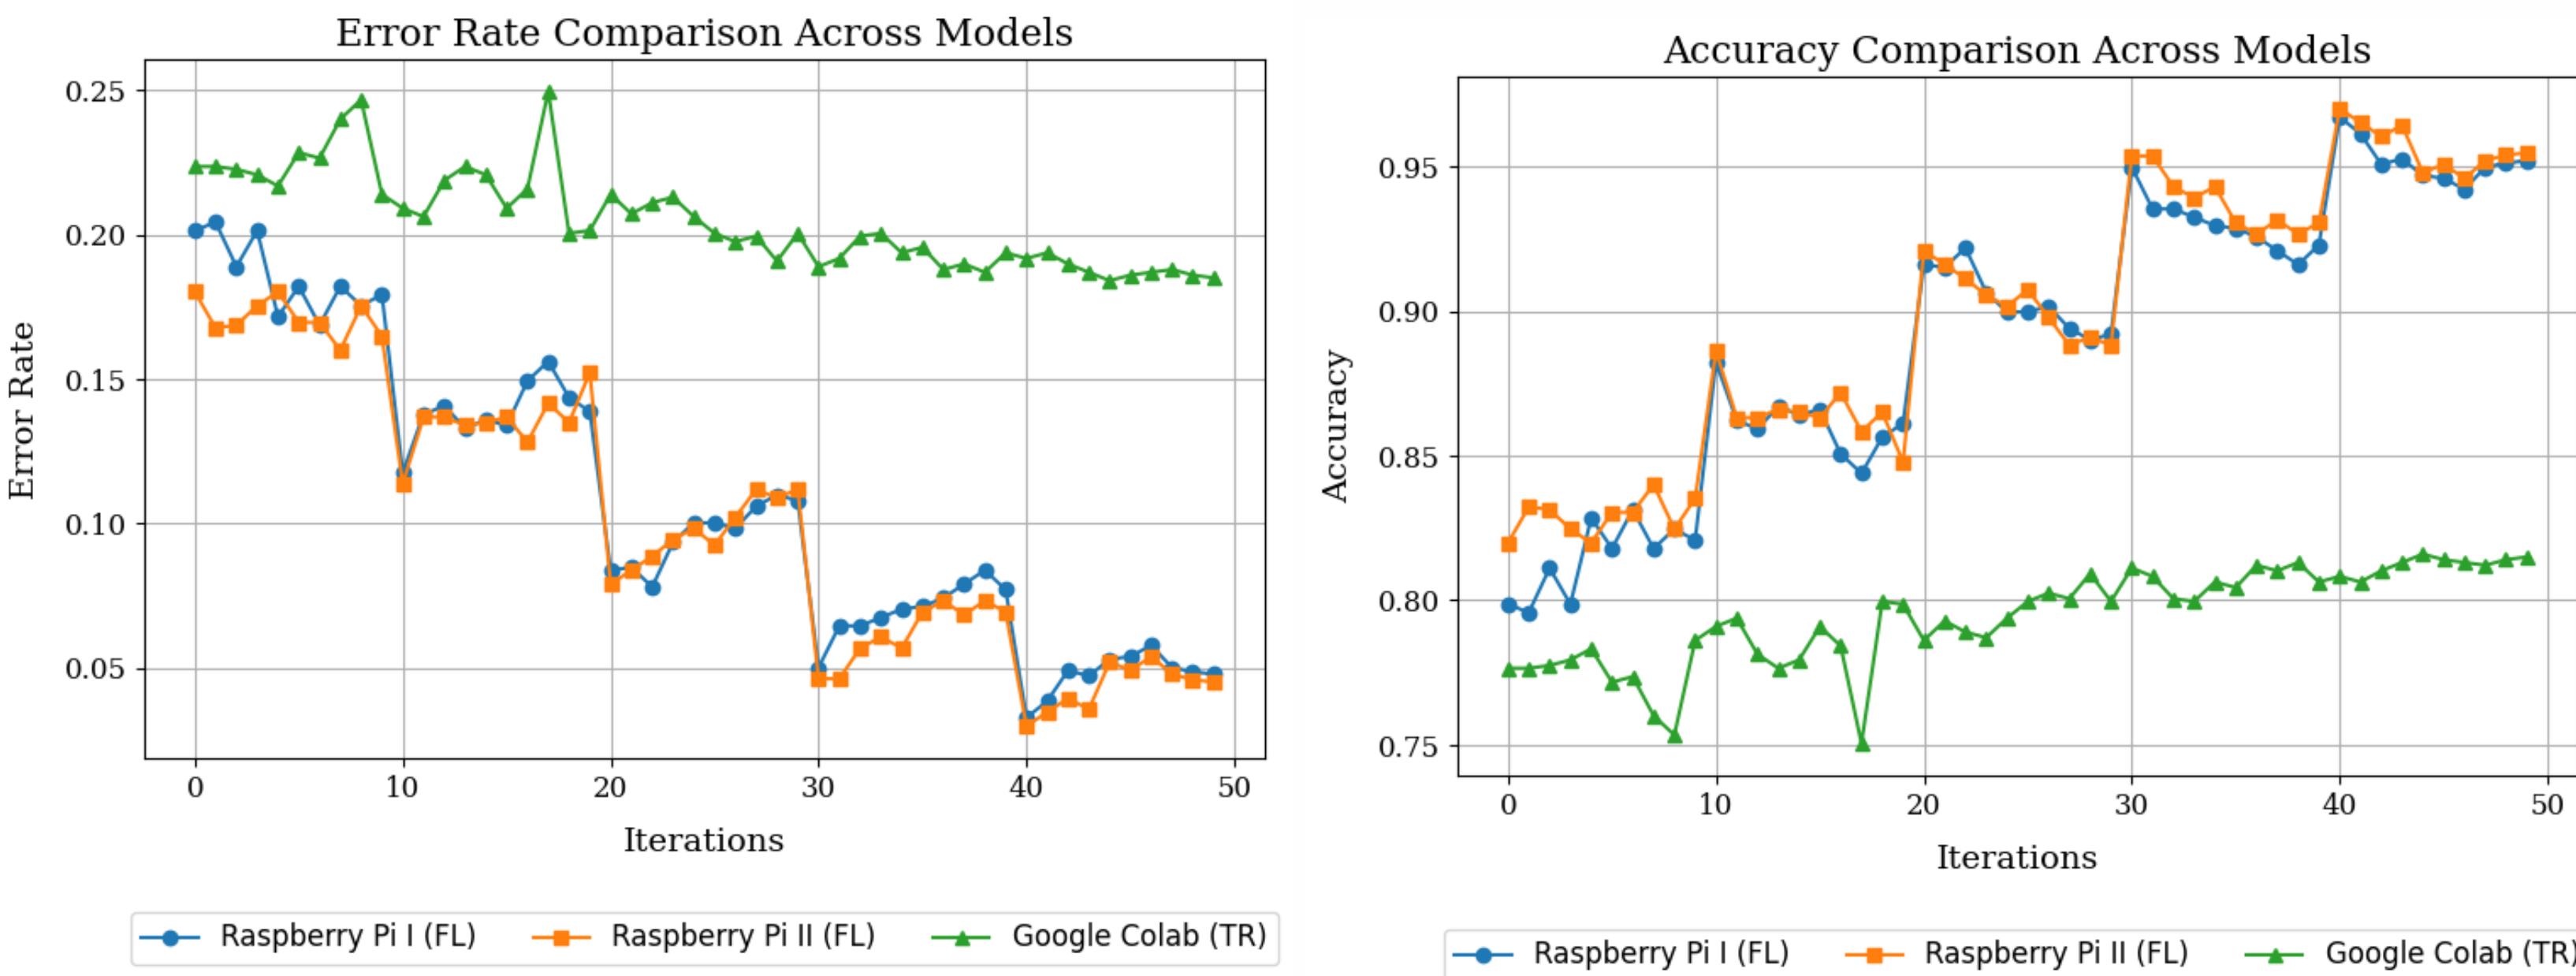
O modelo SqueezeNet treinado no Google Colab obteve uma acurácia de 81,5%, enquanto o treinamento federado do mesmo modelo resultou em uma acurácia de 95,2% e 95,5%. Isto sugere que o treinamento descentralizada pode oferecer acurácia superior e benefícios adicionais, como a preservação da privacidade dos dados.



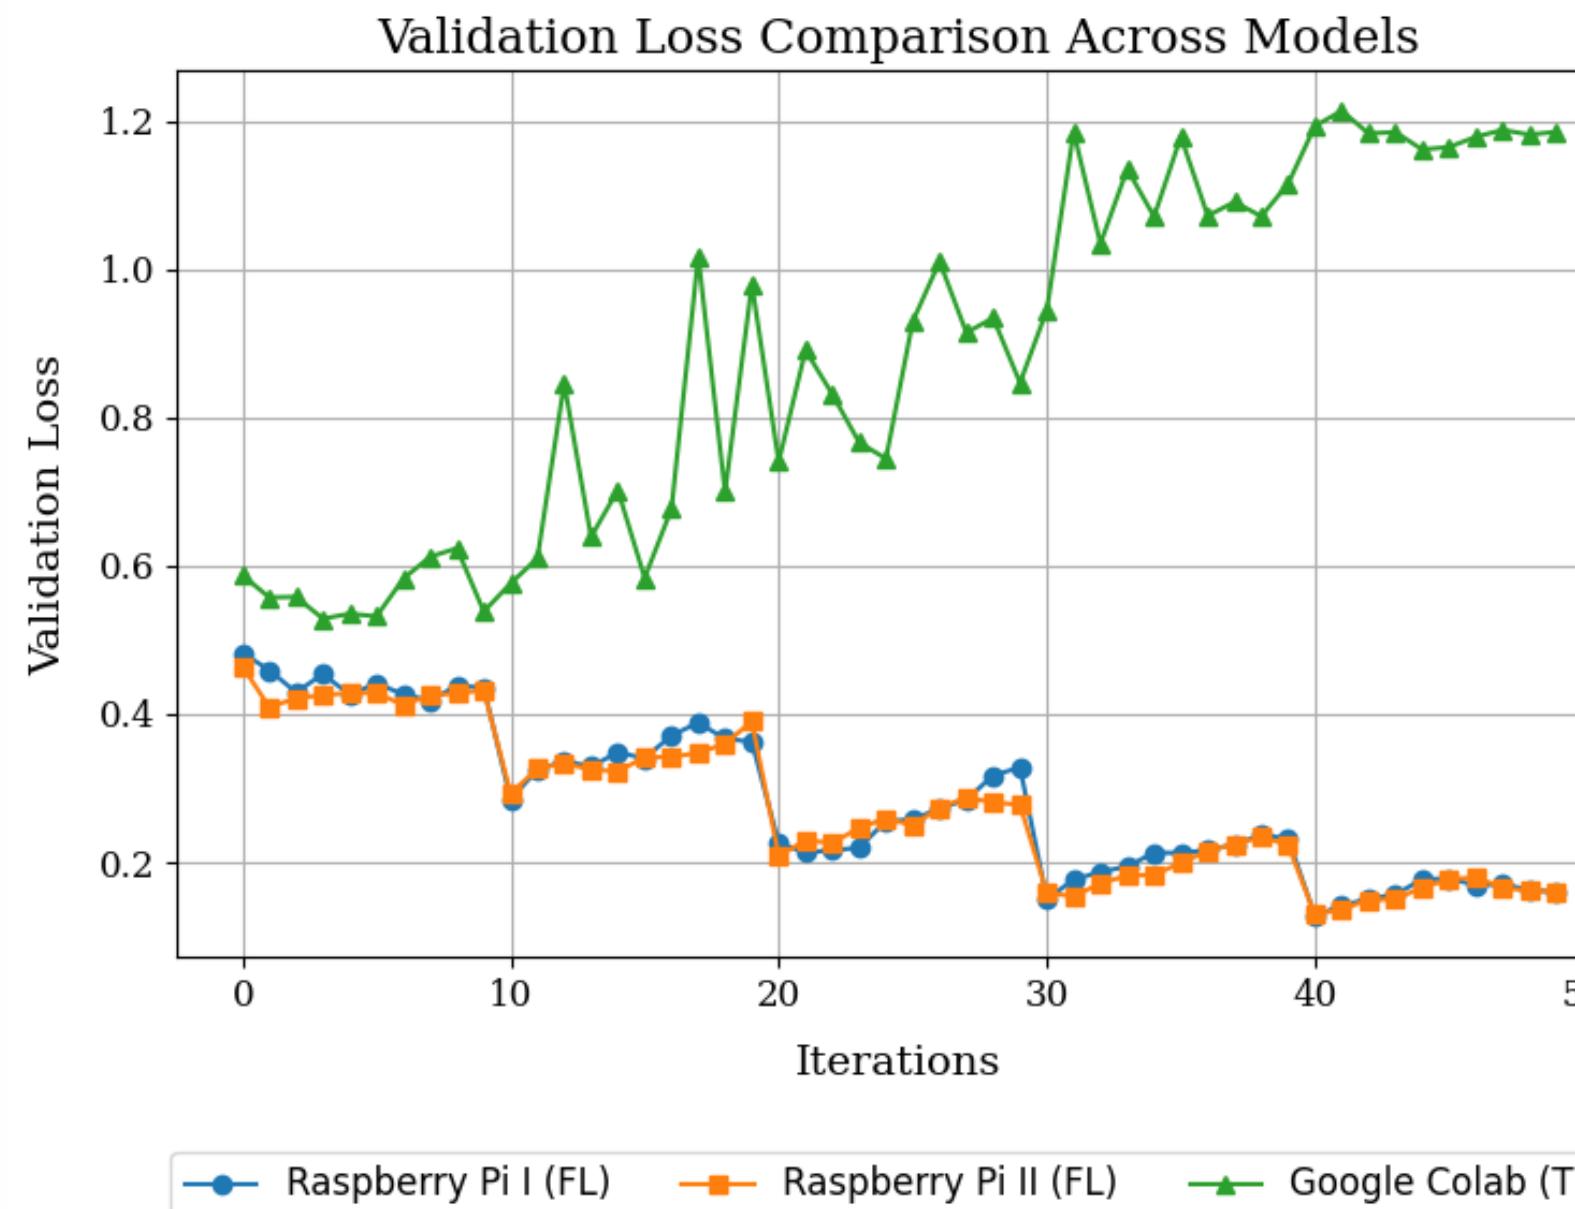
02

ERROR RATE & ACCURACY

Inatel



02 VALIDATION AND TRAIN LOSS



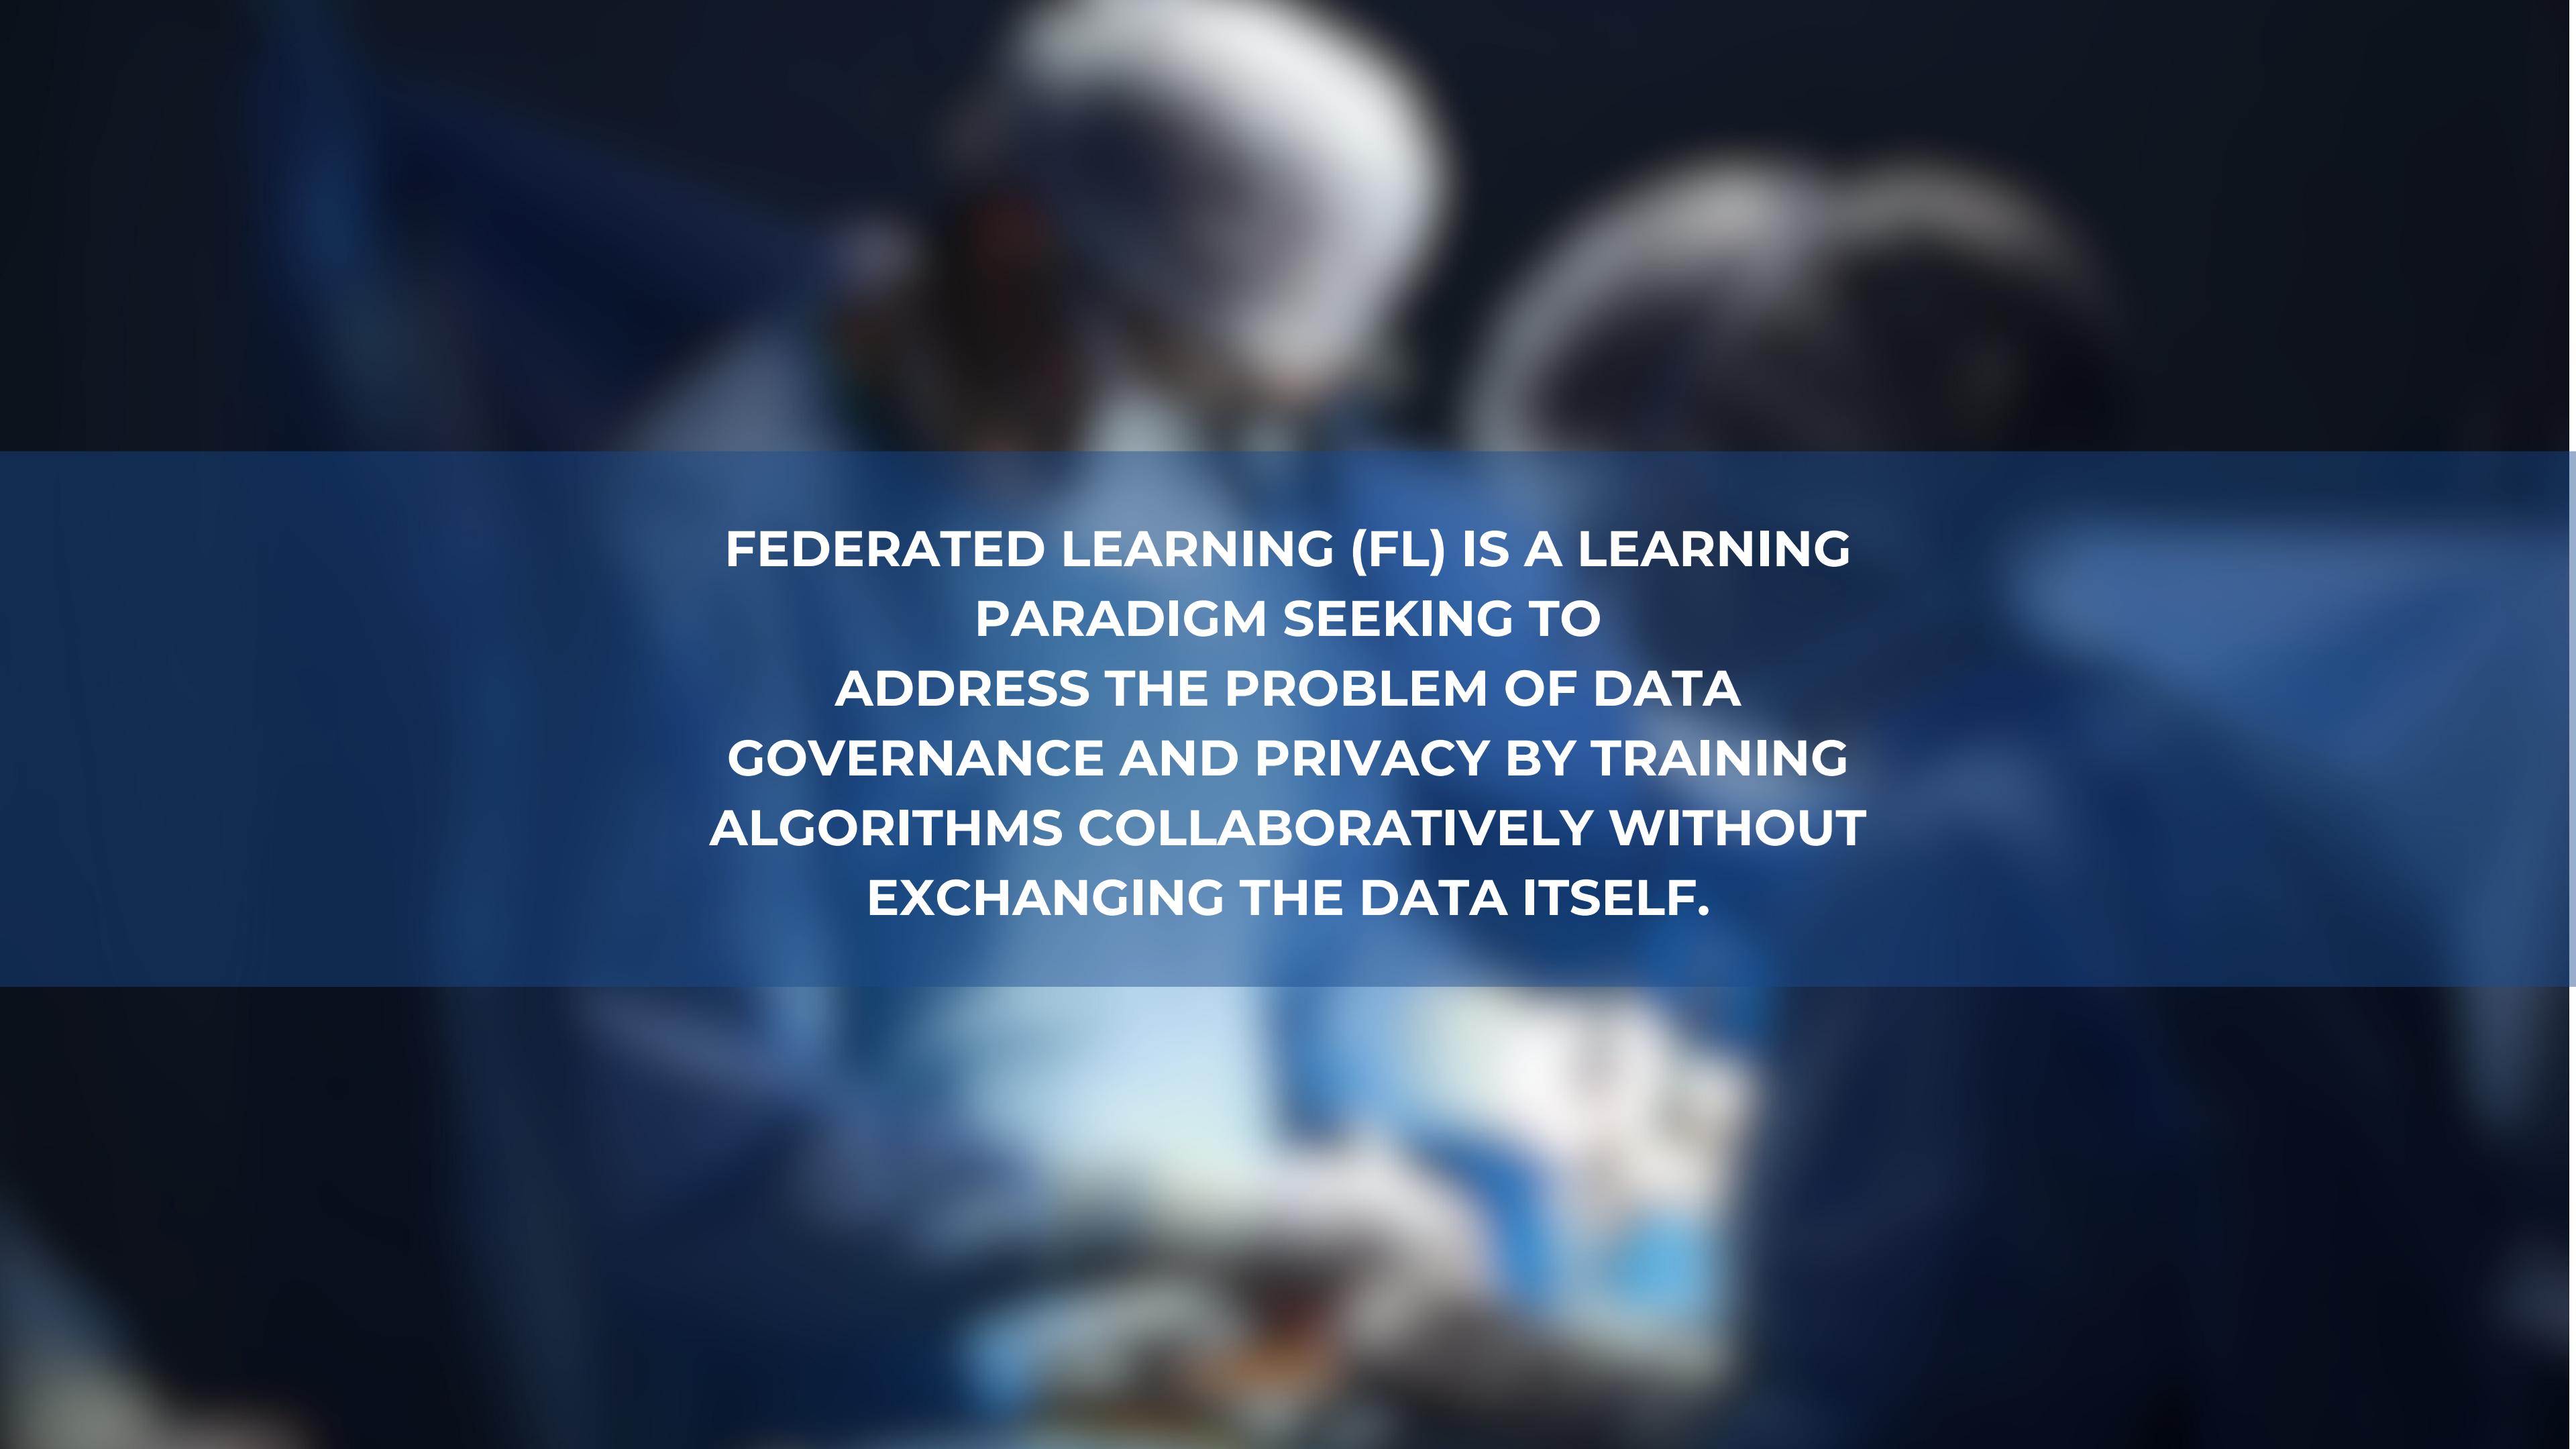
CONCLUSÃO NA SAÚDE

Inatel

CONCLUSÃO

A arquitetura squeezenet e aprendizado federado (FL) para identificar pneumonia causada por bactérias e vírus, apresentou melhorias significativas em todas as métricas em comparação com a abordagem tradicional. O treinamento do modelo levou a um aumento de temperatura no Raspberry's, sugerindo a necessidade de monitoramento da temperatura em trabalhos futuros, o que mostra a necessidade de um modelo com menos operações por ciclo mostrado no slide 6.

O modelo se mostrou eficaz, comparável a modelos modernos e robustos. Trabalhos futuros poderiam incluir o aumento do número de dispositivos para reduzir a quantidade de dados para cada dispositivo IoT, tornando o treinamento menos robusto e mais rápido. Melhorias futuras podem ser feitas realizando um estudo de caso com pacientes reais no hospital e verificando a aplicação com os médicos, integrando-o em celulares e computadores com interfaces de usuário interativas e simples de usar.



**FEDERATED LEARNING (FL) IS A LEARNING
PARADIGM SEEKING TO
ADDRESS THE PROBLEM OF DATA
GOVERNANCE AND PRIVACY BY TRAINING
ALGORITHMS COLLABORATIVELY WITHOUT
EXCHANGING THE DATA ITSELF.**

COMO DIZIA MINHA EX:
TERMINAMOS!

Obrigado :)

